[Java Thread] In Java können Threads mittels Vererbung hergestellt werden. Hierzu gibt es die Basisklasse Thread. Beim Ableiten von der Klasse muss nur public volid run() überschrieben werden. Für den Start des Threads muss dann die Methode start() aufgerufen werden. EIN AUFRUF VON run() WÜRDE BLOCKIEREN!

```
class MyThread extends Thread {
  public void run() {
    do_something();
  }
}
//...
public static void main(String args[]) {
    (new MyThread()).start();
}
```

Des Weiteren gibt es das Runnable Interface, welches ähnlich dem Thread funktioniert. Es kann von einer Klasse implementiert werden. Auch hier muss die Methode public void run() überschrieben werden. Jedoch muss dann eine Instanz des neuen Runnables der Thread-Klasse im Konstruktor übergeben werden.

```
class MyRunnable implements Runnable {
  public void run() {
    do_something();
  }
}
///...
public static void main(String args[]) {
    (new Thread(new MyRunnable())).start();
}
```

Lambdas sind eine weitere Möglichkeit um einen Thread zu erstellen. Hier wird dem Konstruktor von **Thread** ein Lambda übergeben und der Thread gleich gestartet.

```
public static void main(String args[]) {
  (new Thread(() -> {
     do_something();
     })).start();
}
```

Eine vierte Möglichkeit wäre eine anonyme innere Klasse.

Eine spezielle Art von Threads sind **Daemon Threads**. Diese Threads verhindern das Beenden des Programms NICHT. Der **Garbage Collector** ist ein solcher Thread.

```
public static void main(String args[]) {
    // ...
someThread.setDaemon(true);
someThread.start();
    // wait for user input
    // otherwise program will stop
System.in.read();
} Sie brechen beim JVM-Ende unkontrolliert ab
```

notify nur bei:

- 1 Wartebedingung
- es DARF nur einer weiter machen

Monitor:

[synchronized] Für einfachen (ineffizienten) gegenseitigen Ausschluss (mutual exclusion) gibt es das synchronized Schlüsseihuort. Es muss vor dem Typ der Funktion angegeben werden. Der Auschluss via synchronized funktioniert mittels eines Monitor-Docks (siehe Monitor Object [POSA2]). Es kann inmer nur ein Thread eine synchronized Methode auf einem Objekt ausführen. Alle anderen müssen warten, selbst wenn sie eine andere synchronized Methode aufrufen. synchronized kann auch auf Block-level verwendet werden. Die Synchronisierung mittels synchronized ist reentrant, das heisst ein Thread kann mehrere synchronized Methoden verschachtelt aufrufen.

```
public class MyClass {
  public synchronized void syncMethOne(){
    dangerous_things();
  }
  public synchronized void syncMethTwo(){
    dangerous_things();
  }
  public void partlySync(){
    non_dangerous_things();
    synchronized(this) {
    dangerous_things();
  }
  }
}
```

Da jedes Objekt ein Monitor Lock besitzt kann auf jedem Objekt gesynchronized werden (also auch auf Member-Objekten). Bedingungen sollten in synchronized Methoden mit while geprüft werden, da sonst die Gefahr besteht dass man fälschlicherweise weitermacht. Warten kann man mit wait() und notifizieren mit notify und notifyAll() wobei notify() irgendeinen (!!!) wartenden Thread weckt. FAUSTREGEL: Bei unterschiedlichen Wartebedingungen mit notify Werken.

Vorsicht: Sobald wait() benutzt wird, muss die throws InterruntedException verwendet werden

[Semphore] sind "Zähler". Mit acquire() wird eine "Marke" entfernt, mit release() eine zurückgelegt. acquire() blockiert, falls gerade keine "Marke" frei ist. Semaphore können falir sein (new Semanhore(n true)) und folgen dan dem EIFO-Prinzin

Semaphoren können auch negativ initialisiert werden [Locks & Conditions] können verwendet werden um ähnliche Funktionalität wie beim Monitor zu erreichen, mit dem grossen Unterschied, dass hier die Wartebedingungen gezielt "notifiziert" (via signal()) werden können. Jedem Lock können mehrere Conditions zugeordnet sein, auf welche Threads via await() warten können.

```
public class MyClass {
 // fair lock
 private Lock mon = new ReentrantLock(true):
  // Conditions
 private Condition con1 = mon.newCondition()
  private Condition con2 = mon.newCondition()
  public void put(){
   mon.lock()
      while (canPut == false) {
        con1.await();
      // do put
      con2.signal();
   } finally { mon.unlock(); }
 public void get(){
   mon.lock()
    try {
      while (canGet == false) {
        con2.await();
      // do put
     con1.signal();
   } finally { mon.unlock(); }
```

[Read-Write-Locks] erlauben feingranulares Sperren. Da Sperren nicht nötig ist wenn alle Threads nur lesen, können beliebig viele Threads gleichzeitig ein Read-Lock halten, jedoch nur einer ein Write-Lock. Read-Write-Locks können NICHT geupgraded werden.

[CountdownLatch] bietet einen "Einweg-Synchronisationspunkt". Bei der Initialisierung muss angegeben werden, auf wieviele Threads gewartet werden soll. Threads verwenden countDown() auf dem Latch um den Zähler zu dekrementieren. Mit await() wird gewartet bis der Latch auf 0 ist. Der Latch kann nicht wiederverwendet werden.

[CyclicBarrier] ist ähnlich wie CountdownLatch, kann aber wiederverwendet werden. Sie wird bei await() dekrementiert; getParties() ermittelt die Anzahl Teilnahmer der Barriere.

[Phaser] stellt eine verallgemeinerte CyclicBarrier dar. Mit arriveAndAwaitAdvance() wird auf die Freigabe gewartet. Threads können sich mit register() am Phaser an- und mit arriveAndDeregister abmelden.

[Exchanger] ermöglicht es, zwischen zwei Threads Objekte auszutauschen. exchange(obj1) wartet, bis der andere Thread auch exchange(obj2) aufgerufen hat.

[Race Conditions] werden in low-level (Data Race) und highlevel (Semantic Race) unterteilt. Low-level Races treten auf wenn unsynchronisiert auf den gleichen Speicher (Variable, Array-Element, ...) zugegriffen wird. **High-level** Races sind Race-Conditions in der Programmlogik. Sie treten auf, wenn die Critical Sections nicht ausreichend geschützt sind.

Auf Synchronisierung kann verzichtet werden, wenn entweder **Unveränderlichkei**t (z.B Java final) gegeben ist oder veränderliche Objekte in breits synchronisierte Objekte eingesperrt sind (**Confinement**).

[Collections] aus java.util sind grundsätzlich nicht threadsafe. Es gibt jedoch threadsafe Collections in java.util.concurrent.

[Deadlocks] treten auf wenn sich Threads gegenseitig sperren. Folgende Bedingungen müssen eintreten damit es einen Deadlock gibt: Geschachtelte Locks UND Zyklische Warteabhängigkeiten UND Gegenseitiger Ausschluss UND Kein Timeout. Deadlocks lassen sich durch Einführen einer linearen Sperrordnung oder grobaranularer Sperrung lösen.

[Starvation] tritt ein wenn einem Thread immer wieder die Möglichkeit zu arbeiten "weggeschnappt" wird. Dies lässt sich durch **faire** Synchronisationsprimitiven lösen.

[Thread-Pools] besitzen eine Task Queue in welcher Tasks eingereiht und dann von einem freien Worker Thread bearbeitet werden. In Java erzeugt man Thread Pools mit der Factory Klasse Executors. Zur Auswahl stehen newFixedThreadPool(nofThreads), newChachedThreadPool() (automatische Thread Zahl) und newWorkStealingPool(). Gesondert gibt es noch den ForkJoinPool, welcher es erlaubt, rekursive Tasks zu formulieren. Thread Pools haben den Vorteil, dass nicht unnötig viele Threads erzeugt werden. Einschränkung: Tasks dürfen nicht von einander abhängig sein (Deadlock-Gefährt). Nur der ForkJoinPool selzt Daemon Threads ein, alle anderen Pools müssen mit myPool.shutdown() beendet werden. Tasks werden mittels des Callable Interfaces implementiert:

```
class CalcTask implements Callable
Class CalcTask implements Callable
@Override
public Integer call() throws Exception {
   int val = 42;
   // long running stuff
   return val;
   }
ExecutorService pool =
   ExecutorService pool =
   Executors.newFixedThreadPool(2);
Future<Integer> fut1, fut2;
// ...
fut1 = pool.submit(new CalcTask());
fut2 = pool.submit(new CalcTask());
// ...
int res1 = fut1.get();
int res2 = fut2.get();
// ...
pool.shutdown();
```

```
class MSTask extends RecursiveAction {
 private static final int THRESHOLD = 1;
 private int[] array;
 private int p1, p2;
 public MSTask(int[] array,int p1, int p2) {
   this.p1 = p1; this.p2 = p2;
   this . array = array;
 @Override
 public void compute() {
   if (parameter > THRESHOLD) {
     int mid = (p1+p2)/2;
     MSTask t1 = new MSTask(array, p1, mid);
     MSTask t2 = new MSTask(array, mid, p2);
     invokeAll(t1, t2);
     merge(array, p1, mid, p2);
     else
     mergeSort(array, p1, p2);
ForkJoinPool pool = new ForkJoinPool():
pool.invoke(new MSTask(array, 0, array.length));
```

[Futures] repräsentieren zukünftige Ergebnisse (sie sind Proxies im Sinne des PROXY Patterns [GoF]) welche mittels get() abgeholt werden. get() blockiert, bis ein Ergebenis da ist! Beim Auffreten einer unbehandelten Exception liefert get() diese geschachtelt in einer ExecutionException. Mittels cancel() kann ein Task aus der Warteschlange entfert werden (bricht aber nicht den laufenden Task ab).

[Work Stealing] ist ein Verfahren das bei Thread Pools eingesetzt wird bei welchem es eine globale FIFO Queue und für jeden Worker Thread eine locale LIFO Queue gibt. Tasks in der globalen Queue werden (per Delault) "vernachlässigt" aber der Work Stealing Pool kann auch auf FIFO umgestellt werden.

[Asynchrone Aufrufe] erlauben das Auslagern von langen Operationen auf einen anderen Thread oder Pool. Es gibt zwei Ansätze: Caller-zentrisch (pull) und Callee-zentrisch (pull) setzt auf Future Objekte während pull auf Completion Callbacks setzt. Für Completion Callbacks eignet sich als Interface, z.B. iava-uitif_Lunction_Consumer

```
interface Consumer<T> {
    void accept(T result);
}
// ...
void asyncOp(int in, Consumer<Integer> cb) {
    pool.submit(() → {
        Integer res = longOperation(in);
        cb.accept(res);
    });
}
// ...
asyncOp(42, res → {
        System.out.println(res);
});
```

[Continuations] bieten in Java 8 eine Möglichkeit, eine Folgeoperation an einen Task anzuhängen. Dazu verwendet man Completable-Future-Ts.

```
CompletableFuture<Long> fut = CompletableFuture.supplyAsync(() -> longOp()); //...
fut.thenAccept(res -> System.out.println(res));
```

Die Continuation läuft auf dem Initiator **NUR WENN** die Future das Ergebnis schon hat, sonst auf einem beliebigen Worker Thread. Mittels allOf() und any() kann eine Continuation an mehrere Futures gebunden werden.

```
// wait for ALL Futures to arrive
CompletableFuture .allOf(fut1 , fut2)
.thenAccept(cont);
// wait for ANY Future to arrive
CompletableFuture .any(fut1 , fut2)
.thenAccept(cont);
```

[.NET] Threads "funktionieren" ähnlich wie Java Threads, nur ohne Vererbung sondern mit **Delegates** und mit dem Unterschied, dass **uncaught Exceptions** per Default zum **Programmabbruch** führen. Hier ein Threading-Beispiel mit einem Lambda:

```
Thread myThread = new Thread(() => {
    for(int i = 0; i < 100; ++i) {
        Console.WriteLine("Step_{0}", i);
    });
// ...
myThread.Start();
myThread.Join();
```

Im Gegensatz zu Java 8 können in .NET Lambdas auch **non-final** Variablen aus dem umgebenden Scope (via Referenzen) zugegriffen werden (AUCH SCHREIBEND!!!) was die Chance auf **low-level** Range arhöht

[Delegates] sind vergleichbar mit Funktionszeigern welche ein implizites this besitzen. Sie sind damit leichgewichtiger als Java Interfaces, da sie keine Vererbungshierarchie aufweisen. Lambdas sind im Prinzip eine Abbildung von Delegates.

[Monitor] ist in .NET über lock(someObj) verfügbar, welches ähnlich wie synchronized vor einen Block gehängt wird. Best Practice: sperre ein Hilfsobjekt und nicht das eigene Objekt. Zum Warten und Benachrichten werden Monitor.Wait(lock), Monitor.Pulse() und Monitor.PulseAll() verwendet. Der .NET Monitor ist fair und Pulse() weckt immer den Thread, der schon am längsten wartet.

```
class Account {
    // ...
    private object syncObject = new object();

public void syncOp1() {
    // ...
    lock(syncObject) {
        dangerous_things();
        Monitor.PulseAll();
    }
}
```

[Andere Primitiven] in .NET sind analog zu Java, ausser den tehlenden Locks & Conditions und den fehlenden Fairness Flags. Dazu kommen ReadWriteLockSlim (upgradable), Mutex (binärer Semaphor) und speziellere. Ausser den Collections in System.Collections.Concurrent sind alle Collection NICHT Threadsafe.

[TPL] (Task Parallel Library) ist ein Work Stealing Thread Pool mit verschiedenen Abstraktionsebenen (Task Parallelism, Data Parallelism, Asynchronous Programming with Continuations). Die TPL erkennt geschachtelte Tasks seiber und es sind keine speziellen Vorkehrungen zu treffen. Des Weiteren erzeugt die TPL seiber neue Threads wenn sie merkt, dass alle Threads blockiert sind. ACHTUNG: TPL Threads sind Background Threads (analog Java Daemon Threads). Via ThreadPool.SetMaxThreadSn() kann die maximale Anzahl Threads festglelget werden >> Deadlock-Gefahr

```
Task task1 = Task.Factory.StartNew(() => {
// do stuff
});

// wait for task to finish
task1.Wait();

// tasks can have return values
Taskcint> task2 = Task.Factory.StartNew(() => {
   int res = 42;
   return res;
});

// this blocks until task2 is finished
Console.WriteLine(task2.Result);
```

[Exceptions] in Tasks werden seit .NET 4.5 stillschweigend ingoriert und müssen explizit via den Event TaskScheduler.UnobservedTaskException aboniert werden.

[Datenparallelität] kann mittels Bordmitteln erreicht werden. Voraussetzung ist, dass die Unabhängigkeit der Daten gegeben ist! Nach dem Aufruf wird auf die Beendigung ALLER Tasks gewartet.

```
Parallel.Invoke(
   () => Console.WriteLine("foo"),
   () => Console.WriteLine("bar")
);

Parallel.ForEach(list,
   entry => DoStuff(entry)
);

Parallel.For(0, arr.Length,
   idx => MoreStuff(arr[idx])
);
```

[async/await] erlauben das teil-asynchrone Ausführen von Funktionen. Der Compiler zerlegt die Funktion in zwei Hälften: bis zum ersten await wird die Funktion vom Caller synchron ausgeführt, Der Rest wird auf einem TPL-Thread erledigt. await darf nur in Funktionen vorkommen die mit async gekennzeichtet sind und Funktionen die mit async gekennzeichnet sind MÜSSEN ein await enthalten! Das was nach dem await kommt ist die Continuation. Ist der Aufrufer ein UI-Thread dann wird die Continuation auf den UI-Thread dispatched, anderrifalls auf einen TPL-Thread. ACHTUNG: async/await kann zu einem Threadwechsel INNERHALB eines Funktionsaufrufs führen.

```
class MainClass {
  public static async void DoStuff() {
    await Task. Delay(1000);
    Console. WriteLine("Knights!");
  }

public static void Main(string[] args) {
    Console. WriteLine("foo");
    DoStuff();
    // In the meantime 'Knights!' gets
    // written to the console
    Thread. Sleep(5000);
    Console. WriteLine("bar");
  }
}
```

Beispiel für UI-Thread-Dispatching:

```
threadPool.submit( () -> {
  longOperation(); // in different thread
  SwingUtilities.invokeLater(() -> {
    // in UI thread again b/o label
    someLabel.setText("Done!");
  });
});
```

Das Java Memory Model] garantiert Atomicity für Lese-/Schreiboperationen bis 32-Bit (mit volatile auch für long und double) und auf Reiferenzen. Visibility ist bei Locks Release/Acquire garantiert (Anderungen vor Release werden bei Acquire sichtbar). Bei volatile Variablen werden alle vorhergehenden Änderungen beim Zugriff sichtbar. final-Variablen werden nach dem Ende des Konstruktors sichtbar. Sichtbarkeit ist auch bei Thread-Start und -Join sowie Task-Start und -Ende garantiert.

Volatile in JAVA] garantiert, dass kein Reordering über einen Zugriff (lesend oder schreibend) auf eine derart markierte Variable hinaus statt findet. Das Ordering vor und nach volatile folgt innerhalb eines Threads der "As-If-Serial"-Semantik. Das heisst, der Compiler darf optimieren, falls die Semantik INNERHALB des Threads gleich bleibt. Zwischen Threads ist Ordering nur bei Zugriffen auf volatile-Variablen und bei Synchronisationsbefehlen garantiert. volatile Zugriffe führen nicht zu locking.

[Atomare Operationen] erlauben das atomare Ändern einer Variable mit einer zusätzlichen Operation (meistens return des alten Werts). Es gibt für Atomare Klassen für Boolean, Integer, Long und Referenzen (auch für Array-Elemente). Seit Java 8 gibt es auf diesen sogar Operationen welche ein "Expression-Lambda" nehmen. Atomare Operationen garantieren Ordering und Visibility. Beispiele für atomare Operationen sind getAndSet(newVal), getAndAdd(delta) und undateAndGet(lambda).

```
public class SLock {
  private AtomicBoolean locked =
    new AtomicBoolean(false);

public void acquire() {
    // spin if already locked
    // else set locked to true
    while (locked.getAndSet(true)) {
        Thread.yield();
    }
}

public void release() {
    // set false and make visible
    locked.set(false);
    }
}
```

[compareAndSet(old, new)] erlaubt das atomare Prüfen einer Variable auf einen bestimmten Wert und ersetzt sie bei Übereinstimmung mit new. Rückgabewert zeigt ob die Ersetzung stattgefunden hat. ACHTUNG: Hier kann man in das ABA-Problem laufen.

```
do {
  oldV = var.get();
  newV = calcChanges(oldV);
} while (!var.compareAndSet(oldV, newV));
```

Das [ABA-Problem] beschreibt, was passiert wenn ein anderer Thread dazwischen schreibt und sich der zu vergleichende Wert scheinbar nicht ändert. Dies ist besonders bei lockfreien Datenstrukturen wie Stacks und Listen ungünstig.

[Das .NET Memory Model] unterscheided sich vom Java Memory Model darin, dass long und double auch mit volatile nicht atomar sind. Auch die Visibility ist nicht explizit definiert, da sie durch das Ordering gegeben ist. Beim Ordering ist es wichtig, dass volatile in NET nur ein "Partial Fence" ist

[volatile in .NET] verfolgt beim Lesen die sogenannte Acquire-Semantik, was bedeutet, dass alles was VOR dem LESEN einer volatile Variable nach "unten" optimiert werden darf. Beim Schreben wird die Release-Semantik angewandt: alles was NACH dem SCHREIBEN kommt, darf nach oben optimiert werden. Da diese Semantik of ungenügend ist, gibt es mit Thread.MemoryBarrier() einen "Full-Fence".

[GPU Vokabular]: Eine GPU besteht aus mehreren Streaming Multiprocessors (SM). Jeder SM besteht aus mehreren Streaming Processors (SP). In CUDA sind Threads in Blöcke zusammengefasst. Jeder SM kann mehrere Blöcke beherbergen, jeder Block ist intern in Warps zu je 32 Threads zerfegt.

[SIMD] ist die Abkürzung für "Single Instruction Multiple Datat". Dies entspricht dem Paradigma der Verktorparallelität. GPUs sind inherent für SIMD-Applikationen geeignet, denn innerhalb eines SM führen alle Cores die gleiche Instruktion auf unterschiedlichen Daten aus. Es dibt auch in CPU begrenzt mächtige SIMD-Instruktionen.

[CUDA] ist die "Computer Unified Device Architecture" von NVIDIA. CUDA arbeitet mit sogenannten Kernels welche auf der GPU laufen. Jeder Kernel bekommt Informationen darüber, auf welchem Block er läuft (blockldx.x), welcher Thread innerhalb des Blocks er ist (threadldx.x) und wie gross ein Block ist (blockDim.x). Auch die y- und z-Dimensionen sind nutzbar. Als Programmierer muss man die Datenaufteilung selber modellieren. Divergenz heisst, dass im selben Warp unterschiedliche Instruktionen vorhanden sind (z.B. via if/else). Dies bewirkt, dass je für die "i"- und "else"-Elemente ein Cycle gebraucht wird. »- Performanoe-Probleme

Das [CUDA Memory Management] kennt die drei wichtigen Funktionen cudaMalloc, cudaFree und cudaMemopy welche ähnlich wie ihre C-Geschwister funktionieren. Mit cudaMalloc kann Speicher im Device Global Memory alloziert werden. cudaFree gibt allozierten Speicher auf dem Device wieder frei und cudaMemopy wird verwendet um Daten vom Host zum Device zu kopieren.

Maximale Thread-Zahl:

Gegeben: Threads per Block: 1024, Matrix size: 256*512, Anzahl SMs: 3, Max. Resident Threads/SM: 2048, Max. Resident Blocks/SM: 46

Limit A: 3 * 2048 (Max. Res. Threads/SM) tiefste Zahl = Limit Limit B: 3 * 16 * 1024 (Max. Res. Blocks) Limit C: 256 * 512 (# Threads überhaupt, wegen Matrix Size)

Das "CUDA-Grundgerüst" ohne Error Handling sieht in etwa so

```
void CudaVAdd(float* A, float* B,
             float* C, int N)
 size_t size = N * sizeof(float);
 float *d_A, *d_B, *d_C;
 cudaMalloc(&d_A, size);
 cudaMalloc(&d_B, size);
 cudaMalloc(&d C, size);
 cudaMemcpy(d A, A, size,
            cudaMemcpyHostToDevice);
 cudaMemcpy(d B, B, size,
            cudaMemcpyHostToDevice);
  // for 2/3 dimensions: dim3 qDim(32, 32);
 int bDim = 512; //block size
 int \ gDim = (N + bDim - 1) / bDim
 vecAKern<<<gDim, bDim>>>(d_A, d_B, d_C, N);
 cudaMemcpy(C, d C, size,
            cudaMemcpyDeviceToHost);
 cudaFree(d_A); cudaFree(d_B); cudaFree(d_C);
```

[CUDA Function Keywords] sind _global_(lāuft auf Device wird von Host aufgerufen), _device_(lāuft auf Device und wird von Device aufgerufen) und _host_(lāuft auf Host und wird auch vom Host aufgerufen).

[Die Launch-Configuration] muss dynamisch bestimmt werden und sich am Problem und den Fähigkeiten des Device (ermittelt mit

cudaGetDeviceProperties()) orientieren. Aus Effizienzgründen sollte die Blockgrösse ein Vielfaches von 32 sein (remember: 32 Threads per Warp, multiple Warps per Block). Die Blockgrösse sollte auch nicht zu gross gewählt werden, um die Anzahl der unnützen Threads zu minimieren. Die SM sollten voll ausgeschöpft werden (also ans Limit von Resident Blocks und Resident Threads gehen). Grosse Blöcke haben den Vorteil, dass die Threads interagieren können.

[Memory Access] in den Device Global Memory ist viel teuerer (ca. Faktor 125) als Zugriff in den Shared Memory(_shared_) eines SM. Um Memory Coalescing(das Zusammenfassen mehrerer Ladevorgänge zu einem) zu verwenden sollten Speicherzugriffe möglichst folgende Gestalft haben:

```
data[(Ausdruck ohne threadIdx.x) + threadIdx.x]
```

[Synchronisierung] in CUDA kann mit __syncthreads() erreicht werden, was alle Threads in einem Block zum Synchronisieren zwingt.

[Effiziente Matrix Multiplikation]:

```
__shared__ float Asub[TILE_SIZE][TILE_SIZE];
__shared__ float Bsub[TILE_SIZE][TILE_SIZE];
int tx = threadIdx.x, ty = threadIdx.y;
int col = blockIdx.x * TILE_SIZE + tx;
int row = blockIdx.y * TILE_SIZE + tx;
int row = blockIdx.y * TILE_SIZE + ty;

for (int tile = 0; tile < nofTiles; tile++) {
    Asub[ty][tx] = A[row*K + tile*TILE_SIZE + tx];
    Bsub[ty][tx] = B[(tile*TILE_SIZE + ty)*M + col];
    __syncthreads();

for (int ksub = 0; ksub < TILE_SIZE; ksub++) {
    sum += Asub[ty][ksub] * Bsub[ksub][tx];
    }
    __syncthreads();
}
```

[Cluster] weisen spezielle Eigenschafen auf. Erstens gibt es nur innerhalb eines Nodes Shared Memory und nicht über die Grenzen eines Nodes hinweg. Zweitens sind Cluster durch die grosse Anzahl von General Purpose CPUs sehr gut für "allgemeine" Rechenaufgaben geeignet. Im Allgemeinen wird der Austausch von Informationen in Clustern mit Dateien oder über Sockets bewerkstelligt.

[MPI] (Message Passing Interface basiert auf dem Actor- bzw. dem CSP-Modell und ist sehr gut für heterogene Umgebungen geeignet. MPI ist ein Industriestandard einer Bibliothek für Cluster-Anwendungen. MPI ist sogenanntes SPMD (Single Program Multiple Data), da jeder Node das gleiche Programm mit anderen Daten ausführt. Ein Beisniel in C.

```
#include <stdio.h>
#include "mpi.h"
int main(int argc, char* argv[]){
    MPl_Init(&argc, &argv);
    int rank;
    MPl_Comm_rank(MPl_COMM_WOPLD, &rank);
    printf("Process:%i", rank);
    MPl_Finalize();
    return 0;
}
```

Und eines in .NET:

```
using MPI;
using System;
class Program {
  public static void Main(string[] args) {
    using (new MPI.Environment(ref args)) {
      int rank = Communicator.world.Rank;
      Console.WriteLine("Process:{0}", rank);
    }
}
```

[Kommunikation] in MPI kann leicht über Communicator.world erfolgen. Um direkt einem Node eine Nachricht zu senden, verwendet man world.Send(value, receiverRank, messageTag). Analog funktioniert das Empfangen mit world.Receive(senderRank, messageTag, out value). Nachrichten an alle können mit world.Broadcast(ref value, senderRank) abgesetzt UND empfangen werden.Synchronisierung kann mit Communicator.world.Barrier() erreicht werden. Alle Nodes warten darauf, dass alle die Barriere erreichen. Ergebnisse können mittels Allreduce(T value, Op<T>)(Broadcast) oder Reduce(T value, Op<T>, int rank)(ohne Broddcast) reduziert werden. Es existieren noch weitere Kommunikationsmöglichkeiten wie outputArray =

Alltoall(inputArray), value = Scatter(array, rank) oder outputArray = Gather(value, rank).

[.NET PLINQ] via "Extension Methods":

```
salesEurope.
Union(salesAsia).
Union(salesAmerica).
GroupBy (item => item.Article,
item => item.Volume).
Select(category => new {Key = category.Key,
Value = category.Sum()}).
Where(category => category.Value >= 1000);
```

oder mit der eingebetteten Syntax:

```
from entry in salesEurope.AsParallel(). Union(salesAsia.AsParallel()). Union(salesAmerica.AsParallel()) group entry by entry.Article into category let sum = category.Sum(e => e.Volume) where sum >= 1000 select new { category.Key, sum };
```

In PLINQ ist die Reihenfolge der Resultate beliebig (Ordering ist opt-in

[Reactive Programming mit Rx.NET] erlaubt das Reagieren auf eine aktive Quelle (push). Das System basiert auf dem Observer Pattern [GoF]. Um eine Pipeline zu bauen, benötigt man ein Subject das sowohl Observer als auch Observable ist:

```
var subject = new Subject<string >();
subject . Subscribe (Console . WriteLine);
subject . OnNext("A");
subject . OnNext("B");
subject . OnNext("C");
subject . OnCompleted();
```

Normalerweise haben Subjects kein Gedächtnis, es gibt jedoch ReplaySubject, BehaviorSubject und AsyncSubject.

[Software Transactional Memory (STM)] nimmt Ideen aus der Datenbankwelt und versucht damit das Problem des Shared Mutable State ohne Locks und Starvation anzugehen. Es gibt auch Implementationen in Hardware. Meistens wird Optimistic Concurrency Control(Rollback bei Konflikt) als Umsetzung verwendet. In der Java Welt gibt es ScalaSTM, ein deskriptiver Ansatz ("was", nicht "wie") und somit ein relativ einfaches Programmiermodell. Die Implementierung ist iedoch sehr komplex und "teuer".

Das [Actor Model] versucht das Problem zu lösen, dass herkömmliche Sprachen nicht für Nebenläufigkeit entworfen wurden. Dass Threads oft nur Second-Class-Features sind und Speicher per Default nicht threadsafe ist, macht es extrem schwierig KORREKTE nebenläufige Programme zu schreiben.

[Active Objects] (siehe auch [POSA2]) sind Objekte welche ein "Eigenleben" führen. Im Actor Model sind alle Actors Active Objects. Active Objects weist grosse Ähnlichkeiten zu CSP (Communicating Sequencial Processes) auf.

[Akkas Actor Konzept] besteht aus Actors welche nebenläufig zueinander laufen. Sie verfügen jeweils über eine Mail-Box um Nachrichten zu empfangen. Beim Empfangen einer Nachrichte wird eine spezielle Empfangsmethode (onReceive) im Actor ausgeführt.

[ActorRef] speichert eine Referenz auf eine Instanz eines Actors. Dadurch wird verhindert, dass direkt auf Variablen und Methoden des Actors zugegriffen wird. Falls der Actor neu gestartet werden muss, behält er seine Adresse. ActorRefs können in Nachrichten verschickt werden

[Remoting] wird dadurch vereinfacht, dass Nachrichten immutable sind. Ein Lookup für einen Actor kann mittels system.actorSelection(urlString) durchgeführt werden. Das Ergebnis (eine ActorSelection) kann 0-n Aktoren umfassen und zu einer ActorRef aufgelöst werden.

[Messaging] in Akka ist grundsätzlich asynchron. Es kann jedoch mittels Futures synchron auf eine Antwort gewartet werden. Messages müssen Serializable sein, dürfen nur final Felder haben und nicht über Methoden mit Seiteneffekten verfügen. Collections müssen in Collections.unmodifiable List verpackt werden.

```
// synchronous responses
Future<Object> result =
    Patterns.ask(actorRef, msg, timeout);
// ...
result.get();
// custom messages (Java)
public class Booking {
    final String name;

    public Booking(String name) {
        this.name = name;
    }

    public String getName() {
        return name;
    }

    // the same (!!!) in Scala
    class Booking(val name: String)
```

[Das Akka Lautzeitsystem] setzt typischerweise auf ForkJoinPools auf, jedoch wird aus Effizienzgründen nicht ein Thread pro Actor verwendet. Synchrones Senden und Empfangen von Nachrichten führt zu Warteabhängigkeiten, was wiederum zu Deadlocks führen kann. Deshalb wird von synchroner Kommunikation abgeraten.

[Akka Supervision] bezeichnet das Überwachen von Actors durch andere Actors. Eltern überwachen per Default immer ihre Kinder. Bei einer Exception wird der Supervisor informiert und muss dand entscheiden, wie es weiter geht. Der Supervisor hat die Wahl zwischen vier Möglichkeiten: mit Resume kann er dem Kind sapen es soll weitermachen, Restart startet das Kind neu, Stop beendet das Kind und Escalate (siehe Fault Tolerance Patterns) meldet seinem eigenen Supervisor, dass er nicht weiss, wie er reagieren soll.

Der [System Shutdown] erfolgt durch das Stoppen der Actors. Mittels getContext().stop(actorRef) wird einem Actor mitgeteilt, dass er nach Bearbeitung der aktuellen Message anhalten soll. Mit actor.tell(PoisonPill.gethistance(), sender) wird eine Terminierungsnachricht eingereiht, deren Bearbeitung den Actor stoppt. Als "last measure" dient actor.tell(Kill.getInstance(), sender), was eine Supervision Behandlung auslöst.

Verteilung: Actor (Comm. via Messages, no shared state), Reactive

No Race Conditions: Actor (no shared mem., Comm synch'd), Reactive, STM (autom. isoliert)

No deadlocks: Reactive (Flow ist async, non-blocking, STM (kein Warten, nur Transakt.)